

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC & KỸ THUẬT MÁY TÍNH



BÁO CÁO ĐỒ ÁN TỔNG HỢP TRÍ TUỆ NHÂN TẠO

TÌM HIỂU VỀ TIME SERIES

HỘI ĐỒNG: Khoa học máy tính

GVHD: ThS. Võ Thanh Hùng

GVPB:

—o0o—

SVTH1: Thi Khắc Quân - 2011925

SVTH2: Ngô Thanh Phúc - 2011848

TP. HỒ CHÍ MINH, 12/2022

Mục lục

1	Giới thiệu	1
1.1	Mở đầu	1
1.2	Yêu cầu và mục tiêu của đề tài	1
1.2.1	Yêu cầu	1
1.2.2	Mục tiêu	2
2	Giải quyết vấn đề	3
2.1	Dự đoán các bất thường trong mạng viễn thông	3
2.2	Thuật toán	4
2.2.1	Mạng hồi quy RNN	4
2.2.2	Mạng LSTM (Long Short Term Memory)	4
2.2.3	Ý tưởng cốt lõi	5
2.2.4	Bên trong LSTM	6
3	Dữ liệu	8
3.1	Dữ liệu đầu vào	8
3.2	KPIs	8
4	Hiện thực	10
4.1	Huấn luyện	10
4.2	Cửa sổ dữ liệu	10
4.3	Hàm loss	12
5	Kết quả	13
5.1	MAE	13
5.2	Kết quả đạt được	13
6	Tổng kết và tự đánh giá	15

Danh sách bảng

3.1	Bảng KPI	9
-----	--------------------	---

Danh sách hình vẽ

2.1	Mạng hồi quy RNN	4
2.2	Kiến trúc RNN	5
2.3	Kiến trúc LSTM	5
2.4	Cổng của LSTM	6
2.5	Tầng cổng quên	6
2.6	Tầng cổng vào	7
2.7	Cập nhật trạng thái mới	7
2.8	Quyết định giá trị đầu ra	7
3.1	Bộ dữ liệu theo thời gian thực	8
3.2	Bộ dữ liệu sau khi xóa tính chu kỳ	8
4.1	Cửa sổ dữ liệu	10
4.2	Cửa sổ dữ liệu dùng 24 độ trễ dự đoán 1 đầu ra với độ dịch 24	11
4.3	Cửa sổ với nhiều đặc trưng	11
4.4	Cách cửa sổ hoạt động	12
4.5	Công thức tính MSE	12
4.6	Kết quả huấn luyện bằng hàm MSE	12
5.1	Công thức tính MAE	13
5.2	Kết quả huấn luyện	14
5.3	So sánh khi chạy trên tập test	14

Chương 1

Giới thiệu

1.1 Mở đầu

Trong hơn 20 năm qua, do sự phát triển nhanh chóng của công nghệ thông tin và truyền thông, thế giới đã chứng kiến những thay đổi sâu sắc về xã hội, văn hóa và kinh tế. Đặc biệt, sau 2,5G (GSM), thế hệ thứ ba (3G) và thế hệ thứ tư (4G, LTE, LTE-A), các hệ thống thông tin di động bước vào thế hệ thứ năm (5G). Trong khi đó, kết nối băng thông rộng và công nghệ di động đã được ứng dụng rộng rãi ở các nước phát triển và dần được triển khai ở các thị trường mới nổi trên toàn thế giới.

Với sự bùng nổ về số lượng thiết bị thông minh (ví dụ: điện thoại thông minh, phương tiện thông minh, cảm biến thông minh, v.v.), sự gia tăng nhu cầu truy cập internet qua mạng di động đòi hỏi mạng lưới vô tuyến phải mở rộng quy mô và nâng cấp về cơ sở hạ tầng.

Trong bối cảnh đó, VNPT đã bước qua năm thứ 5 (từ 2017 đến nay) triển khai mạng vô tuyến 4G trên hệ thống nhằm đáp ứng các nhu cầu truy cập dữ liệu tốc độ cao của người dùng. Theo thống kê cho thấy mạng vô tuyến 4G VNPT có số lượng phần tử mạng rất lớn, và nhu cầu lưu lượng data tăng theo cấp số nhân theo hàng năm.

Hiện nay, tất cả các thiết bị đầu cuối thế hệ mới đều hỗ trợ kết nối mạng 4G. Đồng thời, cấu hình từ nhà mạng và cài đặt mặc định trên thiết bị đầu cuối thực hiện lựa chọn kết nối mạng 4G ưu tiên cao hơn mạng 3G. Theo đó, nhu cầu sử dụng dịch vụ data trên mạng 4G tăng trưởng đáng kể.

Bên cạnh đó, số liệu thống kê trên mạng di động VNPT, lưu lượng sử dụng dịch vụ dữ liệu trên 4G chiếm 85% trên tổng các lớp mạng 2G, 3G, 4G. Điều này cho thấy vai trò quan trọng trong việc thiết lập mức độ ưu tiên cao nhằm phát triển và nâng cấp chất lượng mạng 4G so với mạng 2G, 3G hiện hành.

Trong năm 2021, mạng di động VNPT đã triển khai dịch vụ thoại trên 4G (VoLTE), cùng với trải nghiệm dịch vụ thoại và dữ liệu trên nền 4G tốt hơn rất nhiều so với 3G. Do đó, hiện tại và tương lai 4G sẽ chiếm vị trí chủ đạo của mạng di động VNPT.

1.2 Yêu cầu và mục tiêu của đề tài

1.2.1 Yêu cầu

Mạng lưới vô tuyến 4G với quy mô rộng lớn và thường xuyên có những thay đổi dẫn đến việc chịu nhiều ảnh hưởng làm suy giảm chất lượng do các nguyên nhân khác nhau chẳng hạn lỗi phần cứng thiết bị, mất nguồn điện, đứt cáp quang, nhiễu nội hệ thống hoặc nhiễu do yếu tố bên ngoài... Do đó, hàng loạt các yêu cầu mới được đặt ra đối với các vấn đề khai thác và đo

kiểm, đánh giá chất lượng dịch vụ mạng di động 4G. Trong đó, bài toán đo kiểm giám sát chất lượng mạng luôn là mối quan tâm hàng đầu và là một trong những vấn đề quan trọng nhất cần giải quyết của các nhà khai thác mạng viễn thông VNPT.

1.2.2 Mục tiêu

Mục tiêu của dự án là xây dựng hệ thống nhằm dự đoán và cảnh báo bất thường của mạng di động 4G thông qua các chỉ số KPI được thu thập từ các hệ thống giám sát chất lượng mạng và dựa trên nền tảng trí tuệ nhân tạo. Giải pháp được xây dựng dựa trên kinh nghiệm làm tối ưu hóa và quản lý, triển khai các thiết bị viễn thông di động của VNPT-NET cùng với việc áp dụng các thuật toán dự báo Machine learning, AI của Trung tâm RD , VNPT-IT và trường Đại học Bách Khoa Tp HCM để đưa ra các dự đoán sớm và cảnh báo chất lượng mạng trong thời gian ngắn nhất, giúp các nhà quản lý mạng có thể đưa ra kế hoạch xử lý kịp thời. Trên cơ sở mục tiêu dự án đề ra, việc áp dụng kết quả nghiên cứu khoa học vào thực tế vận hành khai thác mạng lưới đem lại những lợi ích sau:

- Nâng cao chất lượng mạng thông qua khả năng can thiệp sớm 12 – 24 giờ, chủ động ngăn ngừa giảm thiểu ảnh hưởng đến chất lượng mạng. Đồng thời, giải pháp cho phép chủ động đề xuất phương án xử lý đối với bất thường có khả năng cao xảy ra.
- Tối ưu nguồn lực nhờ giảm khối lượng công việc giám sát, điều hành mạng, điều phối hiệu quả nguồn thiết bị thay thế dự phòng.
- Nâng cao công tác quản lý với khả năng cải tiến quy trình vận hành khai thác, phát triển nhân lực theo định hướng chuyên sâu.
- Khả năng mở rộng cho các hệ thống vô tuyến 3G, 5G hay các hệ thống IP, chuyển mạch, truyền dẫn có cùng định dạng dữ liệu giám sát theo thời gian.

Các lợi ích kỳ vọng đạt được khi xây dựng và áp dụng kết quả nghiên cứu khoa học vào hệ thống giám sát, cảnh báo mạng vô tuyến:

- Tăng gấp 10 lần hiệu suất (giảm 10 lần khối lượng), tiết kiệm nhân sự cho công việc lọc cell kém so với quy trình thủ công hiện tại.
- Chủ động ngăn ngừa tình trạng suy giảm chất lượng, giảm 30 – 40% số lượng phản ánh khách hàng liên quan tới chất lượng mạng so với hiện nay.
- Phát hiện sớm, chủ động tối ưu hệ thống, giảm 50% số lượng cell kém so với hiện trạng.

Chương 2

Giải quyết vấn đề

2.1 Dự đoán các bất thường trong mạng viễn thông

Dự án sử dụng các giải thuật liên quan đến time series để dự đoán các bất thường trong mạng viễn thông. Time series forecasting là hướng nghiên cứu trong machine learning, deep learning, là một bước quan trọng trong bài toán phát hiện bất thường (anomaly detection). Chẳng hạn như giám sát mạng cảm biến (Sensor network monitoring - Papadimitriou and Yu 2006), Quản lý năng lượng và lưới điện thông minh, phân tích kinh tế và tài chính (Energy and smart grid management, economics and finance (Zhu and Shasha 2002),...


Dự án này tập trung vào việc nghiên cứu các kỹ thuật cụ thể để dự báo các thông số performance counter KPI dựa trên lịch sử lưu trữ của chỉ số đo lường chất lượng các phần tử mạng. Để tiến đến dự đoán sớm phần tử mạng hoạt động bất thường khả quan vì nhiều lý do sau:

- Tính sẵn sàng của performance counter và KPI: Hiện nay đã có hệ thống quản lý tập trung gửi các thông số performance counter và KPI đều đặn theo thời gian và định kỳ cho các trạm quan sát. Trong đó có các performance counter và KPI ở dạng Time Series có thể sử dụng để phân tích và dự báo.
- Tính sẵn sàng của các giải pháp phân tích Time Series: Một Time Series thường được phân rã thành 4 thành phần sau:
 - + Trend: thành phần này chỉ ra xu hướng tổng quan của dữ liệu theo thời gian: lên hoặc xuống, tăng hoặc giảm
 - + Seasonality: thành phần chỉ ra các xu hướng theo mùa vụ, chỉ ra các pattern theo tháng, theo quý
 - + Cycle: thành phần chu kỳ, nó khác seasonality ở chỗ thành phần này có sự vận động trong khoảng thời gian dài hơn (nhiều năm)
 - + Irregular remainder: thành phần nhiễu còn lại sau khi trích xuất hết các thành phần ở trên, nó chỉ ra sự bất thường của các điểm dữ liệu
- Các công trình nghiên cứu về Time Series hiện nay về cơ bản đã có thể dự báo được các chuỗi Time Series bằng các kỹ thuật machine learning cổ điển (sử dụng các thuật toán phân tích) và bằng các kỹ thuật sử dụng đặc trưng deep learning.
- Tính tổng quát cao: bản chất của phát hiện bất thường là phát triển những kỹ thuật cụ thể để: (a) phân tích dữ liệu performance counter KPI; (b) dự báo dữ liệu performance counter KPI mới dựa trên performance counter KPI cũ; (c) phát hiện bất thường dựa trên KPI cũ và KPI dự báo.

2.2 Thuật toán

2.2.1 Mạng hồi quy RNN

Ý tưởng chính của RNN (Recurrent Neural Network) là sử dụng chuỗi các thông tin. Trong các mạng nơ-ron truyền thống tất cả các đầu vào và cả đầu ra là độc lập với nhau. Tức là chúng không liên kết thành chuỗi với nhau. RNN được gọi là hồi quy (Recurrent) bởi lẽ chúng thực hiện cùng một tác vụ cho tất cả các phần tử của một chuỗi với đầu ra phụ thuộc vào cả các phép tính trước đó. Nói cách khác, RNN có khả năng nhớ các thông tin được tính toán trước đó.



Hình 2.1: Mạng hồi quy RNN

Mô hình trên mô tả phép triển khai nội dung của một RNN, được thực hiện:


- x_t là đầu vào tại bước t
- S_t là trạng thái ẩn tại bước t, là bộ nhớ chính của mạng. S_t được tính toán dựa trên cả các trạng thái ẩn phía trước và đầu vào tại bước đó
- O_t là đầu ra tại bước t.

2.2.2 Mạng LSTM (Long Short Term Memory)

Một điểm nổi bật của RNN chính là ý tưởng kết nối các thông tin phía trước để dự đoán cho hiện tại. Nếu mà RNN có thể làm được việc đó thì chúng sẽ cực kỳ hữu dụng, tuy nhiên liệu chúng có thể làm được không? Câu trả lời là còn tùy. Với những khoảng cách nhỏ thì RNN làm tốt, nhưng nếu khoảng cách quá lớn thì RNN không thể lưu trữ được thông tin.


Do đó, ngta dùng mạng LSTM để giải quyết vấn đề này. LSTM được thiết kế để tránh được vấn đề phụ thuộc xa.

Mọi mạng hồi quy đều có dạng là một chuỗi các mô-đun lặp đi lặp lại của mạng nơ-ron. Với mạng RNN chuẩn, các mô-đun này có cấu trúc rất đơn giản, thường là một tầng tanh.



Hình 2.2: Kiến trúc RNN

LSTM cũng có kiến trúc dạng chuỗi như vậy, nhưng các mô-đun trong nó có cấu trúc khác với mạng RNN chuẩn. Thay vì chỉ có một tầng mạng nơ-ron, chúng có tới 4 tầng tương tác với nhau một cách rất đặc biệt.




Hình 2.3: Kiến trúc LSTM

2.2.3 Ý tưởng cốt lõi

- Chìa khóa của LSTM là trạng thái tế bào (cell state). Nó chạy xuyên suốt tất cả các mắt xích (các nút mạng) và chỉ tương tác tuyến tính đôi chút. Vì vậy mà các thông tin có thể dễ dàng truyền đi thông suốt mà không sợ bị thay đổi.

- Các cổng là nơi sàng lọc thông tin đi qua nó, chúng được kết hợp bởi một tầng mạng sigmoid và một phép nhân. Một LSTM có 3 cổng.




Hình 2.4: Cổng của LSTM

- Tầng sigmoid sẽ cho đầu ra là một số trong khoảng $[0, 1]$, mô tả có bao nhiêu thông tin có thể được thông qua. Khi đầu ra là 0 thì có nghĩa là không cho thông tin nào qua cả, còn khi là 1 thì có nghĩa là cho tất cả các thông tin đi qua nó.

2.2.4 Bên trong LSTM


- Bước đầu tiên của LSTM là quyết định xem thông tin nào cần bỏ đi từ trạng thái tế bào. Quyết định này được đưa ra bởi tầng sigmoid - gọi là “tầng cổng quên” (forget gate layer). Nó sẽ lấy đầu vào là h_{t-1} và x_t rồi đưa ra kết quả là một số trong khoảng $[0,1]$ cho mỗi số trong trạng thái tế bào C_{t-1}



$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

Hình 2.5: Tầng cổng quên

- Bước tiếp theo là quyết định xem thông tin mới nào ta sẽ lưu vào trạng thái tế bào. Việc này gồm 2 phần. Đầu tiên là sử dụng một tầng sigmoid được gọi là “tầng cổng vào” (input gate layer) để quyết định giá trị nào ta sẽ cập nhập. Tiếp theo là một tầng tanh tạo ra một véc-tơ cho giá trị mới nhằm thêm vào cho trạng thái. Trong bước tiếp theo, ta sẽ kết hợp 2 giá trị đó lại để tạo ra một cập nhập cho trạng thái.




$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$

Hình 2.6: Tầng cổng vào


- Tiếp theo, ta sẽ cập nhật trạng thái tế bào cũ C_{t-1} thành trạng thái mới C_t . Ta sẽ nhân trạng thái cũ với f_t để bỏ đi những thông tin ta quyết định quên lúc trước. Sau đó cộng thêm.



$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

Hình 2.7: Cập nhật trạng thái mới

- Cuối cùng, ta cần quyết định xem ta muốn đầu ra là gì. Giá trị đầu ra sẽ dựa vào trạng thái tế bào, nhưng sẽ được tiếp tục sàng lọc. Đầu tiên, ta chạy một tầng sigmoid để quyết định phần nào của trạng thái tế bào ta muốn xuất ra. Sau đó, ta đưa nó trạng thái tế bào qua một hàm tanh để có giá trị nó về khoảng $[-1,1]$, và nhân nó với đầu ra của cổng sigmoid để được giá trị đầu ra ta mong muốn.



$$o_t = \sigma(W_o [h_{t-1}, x_t] + b_o)$$

$$h_t = o_t * \tanh(C_t)$$

Hình 2.8: Quyết định giá trị đầu ra

Chương 3

Dữ liệu

3.1 Dữ liệu đầu vào

Để thực hiện đồ án lần này, nhóm chúng em được chuẩn bị bộ dữ liệu gồm giá trị các KPIs theo thời gian thực.

	Datetime	CSSR	USER_DL_AVG_THI	USER_UL_AVG_THI	UL_LATENCY	DL_LATENCY	TRAFFIC	INTRA_FREQUENCY	SERVICE_DROP_AL
479	2021-01-01 0:00:00	99.78303873	17590.11728	801.4966713	0	3.982996844	0	99.58034192	0.4011192258
491	2021-01-01 1:00:00	99.78303873	17590.11728	801.4966713	0	3.982996844	0	99.58034192	0.4011192258
480	2021-01-01 2:00:00	99.78303873	17590.11728	801.4966713	0	3.982996844	0	99.58034192	0.4011192258
493	2021-01-01 3:00:00	100	4000	9.00E-05	0	2.83333	0	100	0
492	2021-01-01 4:00:00	99.78303873	17590.11728	801.4966713	0	3.982996844	0	99.58034192	0.4011192258
487	2021-01-01 5:00:00	100	17590.11728	801.4966713	0	2.66667	0	100	0
488	2021-01-01 6:00:00	100	21550.86171	0.00128	0	3.66197	0.01573	100	0
478	2021-01-01 7:00:00	100	21117.15867	0.00201	0	3.35397	0.01328	100	0
482	2021-01-01 8:00:00	100	20675.92593	0.00198	0	3.58798	0.01866	100	0

Hình 3.1: Bộ dữ liệu theo thời gian thực

Đối với dữ liệu chuỗi thời gian, thường sẽ có tính định kỳ hàng ngày và hàng năm rõ ràng. Để đối phó với tính chu kỳ, chúng em đã sử dụng các phép biến đổi sin và cosin để xóa các tín hiệu "Thời gian trong ngày" và "Thời gian trong năm".

Xóa dữ liệu về thời gian, thêm các giá trị sin và cosin thời gian trong ngày và trong năm. Bộ dữ liệu đầu vào sẽ gồm 11 đặc trưng

	cssr	user_dl_avg_thput	user_ul_avg_thput	dl_latency	traffic	intra_frequency_ho	service_drop_all	Day sin	Day cos	Year sin	Year cos
0	0.011229	0.017468	0.550205	0.003530	-0.430286	0.017041	-0.025316	-0.002096	1.413800	-1.147755	1.558150
1	0.011229	0.017468	0.550205	0.003530	-0.430286	0.017041	-0.025316	0.363894	1.365616	-1.146092	1.558139
2	0.011229	0.017468	0.550205	0.003530	-0.430286	0.017041	-0.025316	0.704943	1.224349	-1.144429	1.558128
3	0.137052	-1.204353	-0.301161	-0.506456	-0.430286	0.151876	-0.179385	0.997808	0.999626	-1.142766	1.558115
4	0.011229	0.017468	0.550205	0.003530	-0.430286	0.017041	-0.025316	1.222532	0.706762	-1.141103	1.558102

Hình 3.2: Bộ dữ liệu sau khi xóa tính chu kỳ

Với tập dữ liệu được cung cấp có 7319 quan sát, chúng em chia tập dữ liệu thành ba tập là tập train dùng để huấn luyện mô hình, tập validation để đánh giá mô hình qua mỗi depoch và tập test để kiểm tra lại mô hình khi quá trình huấn luyện đã hoàn tất.

3.2 KPIs

Để xây dựng hệ thống nhằm dự đoán và cảnh báo bất thường của mạng di động 4G thông qua các chỉ số KPI, nhóm chúng em đã được cung cấp bộ dữ liệu gồm 8 KPI:

CSSR (Call Setup Success Rate)	Xác suất người dùng có thể truy cập thành công từ hệ thống
USER_DL_AVG_THPUT(User Downlink Average Throughput) và USER_UL_AVG_THPUT(User Uplink Average Throughput)	Giá trị thông lượng trung bình của người dùng khi download hoặc upload
UL_LATENCY và DL_LATENCY	Giá trị độ trễ của người dùng khi upload và download
TRAFFIC	Dữ liệu trên mạng tại một thời điểm
INTRA_FREQUENCY_HO (ntra-Frequency Handover)	Giá trị sự chuyển giao hai cell khác nhau chung một tần số LTE
SERVICE_DROP_ALL	Tỷ lệ rớt toàn bộ thiết bị trong mạng

Bảng 3.1: Bảng KPI

Chương 4

Hiện thực


4.1 Huấn luyện

Quá trình huấn luyện nhằm xây dựng mô hình LSTM với:


- Epoch bằng 40.
- Early stopping khi giá trị loss đạt giá trị min để tránh gây ra overfitting
- Thuật toán tối ưu là Adam với learning rate bằng 5×10^{-5} nhằm thực hiện đẩy nhanh tốc độ học với giá trị learnin rate thấp.

4.2 Cửa sổ dữ liệu

Cửa sổ dữ liệu là tập hợp các dự đoán dựa trên một cửa sổ của các mẫu liên tiếp từ dữ liệu. Với đầu vào là độ dài của input, label và khoảng offset. Cửa sổ sẽ chia tập train thành các cửa sổ, với chiều dài cửa sổ bằng tổng độ dài input và khoảng offset. Trong một cửa sổ sẽ có vùng dữ liệu đầu vào dùng để dự đoán các chuỗi dữ liệu đã được dán nhãn. Ví dụ như đưa ra một dự đoán 24 thời gian tới dựa vào 24 thời gian trong quá khứ:

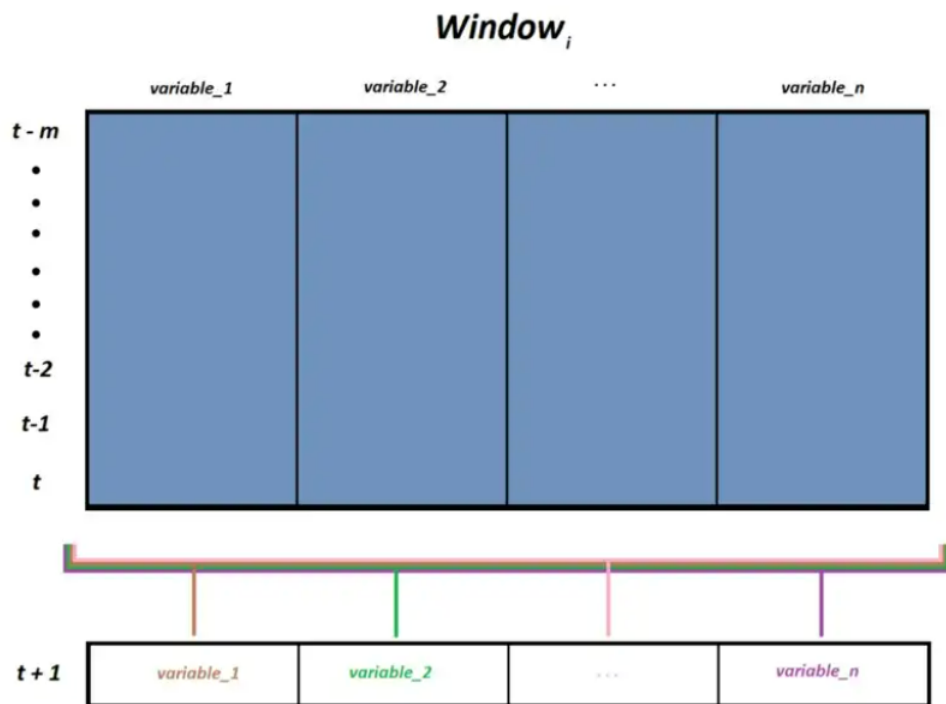


Hình 4.1: Cửa sổ dữ liệu




Hình 4.2: Cửa sổ dữ liệu dùng 24 độ trễ dự đoán 1 đầu ra với độ dịch 24

Tuy nhiên trên đây chỉ là một đầu ra cho một đặc trưng. Đối với bài toán này, nhóm chúng em lựa chọn đầu vào không chỉ là một đặc trưng mà sử dụng đầu vào với 11 đặc trưng.



Hình 4.3: Cửa sổ với nhiều đặc trưng

Ngoài dự đoán một giá trị tại một thời điểm trong tương lai, chúng ta có thể dự đoán nhiều giá trị tại nhiều thời điểm trong tương lai.



Hình 4.4: Cách cửa sổ hoạt động

4.3 Hàm loss


Bản chất của quá trình học máy là với mỗi dữ liệu đầu vào trong quá trình huấn luyện, thuật toán sẽ tìm cách thay đổi các tham số bên trong mô hình để mô hình trở nên tốt hơn trong việc “dự đoán” ở tương lai với những dữ liệu đầu vào xấp xỉ hoặc tương tự. Trong quá trình thay đổi các tham số, hàm mất mát sẽ đóng vai trò đánh giá độ “tốt” của mô hình với một bộ trọng số tương ứng. Mục đích của quá trình huấn luyện là tìm ra bộ số để độ lớn hàm mất mát (loss function) là nhỏ nhất (cực tiểu).

Với mô hình LSTM đang xây dựng trên tập dữ liệu thiếu tính ổn định, nhóm chúng em quyết định chọn hàm mất mát là trung bình phương sai số (MSE). Hàm MSE sẽ tạo ra giá trị chênh lệch rất lớn trong quá trình dự đoán, nhằm thay đổi nhiều trọng số.

$$MSE = \frac{\sum (f_i - y_i)^2}{N}$$

Hình 4.5: Công thức tính MSE

Mô hình được huấn luyện bằng hàm mất mát MSE, giá trị của hàm mất mát trên cả 2 tập train và validation đã giảm được đáng kể, tuy vẫn chưa thể đạt đến mức tối ưu vì hạn chế về số lượng dữ liệu. Tuy vậy vẫn có thể cho thấy sự hiệu quả khi sử dụng MSE làm hàm mất mát.



Hình 4.6: Kết quả huấn luyện bằng hàm MSE

Chương 5

Kết quả

5.1 MAE

Mô hình đang được xây dựng trên bộ dữ liệu có dữ liệu đầu vào là X và có đầu ra tương ứng là Y để huấn luyện bộ tham số của mô hình, hay nói cách khác là mô hình hồi quy. Mô hình hồi quy (Regression model) được sử dụng để dự đoán các giá trị mục tiêu là giá trị liên tục. Các metrics được sử dụng để đánh giá mô hình hồi quy phải có khả năng làm việc với tập các giá trị liên tục, và nhóm chúng em chọn giá trị trung bình sai biệt tuyệt đối (MAE) làm giá trị đánh giá mô hình.

MAE là một phương pháp đo lường sự khác biệt giữa hai biến liên tục. Giả sử rằng X và Y là hai biến liên tục thể hiện kết quả dự đoán của mô hình và kết quả thực tế. chúng ta có độ đo MAE được tính theo công thức sau:


$$MAE = \frac{\sum_{i=1}^n |y_i - x_i|}{n} = \frac{\sum_{i=1}^n |e_i|}{n}.$$

Hình 5.1: Công thức tính MAE

Độ đo này thường được sử dụng để đánh giá sự sai khác giữa mô hình dự đoán và tập dữ liệu testing trong các bài toán hồi quy. Chỉ số này càng nhỏ thì mô hình học máy càng chính xác.

5.2 Kết quả đạt được

Sau khi quá trình huấn luyện mô hình trên các cửa sổ với 30 epoch, mô hình cho ra kết quả như sau:



Hình 5.2: Kết quả huấn luyện

Từ kết quả ta có thể thấy được quá trình học của mô hình dần được cải thiện, nhưng đến khoảng epoch thứ 25 loss của val và train không còn hội tụ nữa do hạn chế về dữ liệu. Ngoài đồ thị giá trị loss còn có đồ thị giá trị MAE, từ đồ thị ta có thể thấy hiệu suất của mô hình gia tăng đáng kể nhưng đến epoch thứ 30 khi việc huấn luyện không giúp mô hình cải thiện thì hiệu suất mô hình cũng không được gia tăng.

Và đây là kết quả khi chạy mô hình trên tập test:

```
Gia trị MAE trên tập validation: 0.5418309569358826
Giá trị MAE trên tập test: 0.581968367099762
```

Hình 5.3: So sánh khi chạy trên tập test

Giá trị đánh giá mô hình khi chạy trên tập test vẫn chưa đạt đến mức yêu cầu nhưng so với bộ dữ liệu mà nhóm em có thì có thể tạm chấp nhận

Chương 6

Tổng kết và tự đánh giá

Với kết quả của mô hình bên trên, mô hình vẫn chưa thể đưa ra một kết quả quá tốt và hoàn thiện để có thể áp dụng mô hình trong việc dự đoán các bất thường của mạng như mục tiêu đã đặt ra vì vẫn còn hạn chế về dữ liệu. Tuy vậy không hẳn thông qua đề án tổng hợp trí tuệ nhân tạo trong kỳ này, nhóm chúng em đã có một thứ đã thu hoạch được:

- Nhóm đã có được một số góc nhìn về công việc khi nghiên cứu và làm việc theo hướng trí tuệ nhân tạo.
- Nhóm đã được tiếp xúc với các kiến thức về cách nghiên cứu, khai phá, tìm hiểu về các đặc trưng của dữ liệu, những lưu ý trong quá trình huấn luyện mô hình. Có kiến thức và cách hoạt động, vận hành của các thuật toán machine learning và deep learning. Ngoài ra còn biết đến các tiêu chí các đánh giá mô hình như MSE, MAE...
- Được làm việc với dữ liệu là các chuỗi thời gian, nhóm được biết các kiến thức về time series, các đặc điểm, tính chất của một chuỗi thời gian và cách khai thác, lưu ý khi khai thác dữ liệu là chuỗi thời gian.
- Nhóm được cung cấp các kiến thức về mạng vô tuyến, nhu cầu truy cập mạng 4G của các thiết bị thông minh, các KPI để đánh giá tình trạng hiện hành của mạng.
- Nhóm còn được hiện thực một mạng deep learning - LSTM để dự đoán tình trạng mạng. Tuy mô hình chưa thể đạt được kết quả như mục tiêu đề ra nhưng đã có những bước cải tiến đến gần hơn với yêu cầu.
- Ngoài ra, nhóm còn được học cách làm việc nhóm, phân chia công việc và phối hợp giữa các thành viên. Được biết cách trình bày, thuyết trình và học được cách viết báo cáo đề án.

Tóm lại, qua phần đề án lần này, nhóm chúng em đã biết cách bắt đầu và hoàn thành một dự án nghiên cứu lĩnh vực trí tuệ nhân tạo.

Tài liệu tham khảo

- [1] Ralf C. Staudemeyer, Eric Rothstein Morris - *Understanding LSTM – a tutorial into Long Short-Term Memory Recurrent Neural Networks*, 2019.
- [2] Bryan Lim and Stefan Zohren - *Time-series forecasting with deep learning: a survey.*, 2021.
- [3] Dirk Bassler, Victor M.Montori, Matthias Briel, Paul Glasziou, Gordon Guyatt - *Early stopping of randomized clinical trials for overt efficacy is problematic.*, 2008